

Response-Distilled Global-Local Wind Dynamics for Static 3D Gaussian Thin Surfaces

Target-Mesh-Free Inference with Topology-Privileged Training

Wind3DGS Project

2026-08-22

Canonical direction as of 2026-08-22

이 문서는 Wind3DGS 의 현재 연구 질문, 방법 경계, 학습 데이터 계약과 구현 Gate 를 소유한다. 이전 Minimal V0 의 explicit anchor scaffold, decoded edge/triplet topology, fixed-Hessian 구조 연산자와 generalized-eigen Global/patch-complement Local solver 는 복구 가능한 archive 와 비교 baseline 으로 남기되, 새 방법의 완료 상태로 승계하지 않는다.

새 방법은 training-only mesh simulation 에서 **force-to-motion response** 를 학습하고, target 에서는 static 3DGS, metric scale, material, attachment 와 prescribed wind 만 사용한다. 네트워크 내부의 patch token 과 latent relation 은 사용하지만 target mesh 나 persistent physical graph 를 외부 산출물로 만들지 않는다. 네트워크의 method output 은 다음 frame 의 absolute deformation 이 아니라 Global 및 Local **response package** 이며, 작은 deterministic response evaluator 가 이를 시간 적분한다. 목표는 universal physical world model 이 아니라 지원한 thin-surface domain 에서 시각적으로 설득력 있고 안정적이며 controllable 한 wind animation 과 measured quality-latency 이득이다.

Contents

1	한눈에 보는 아이디어	4
1.1	핵심 흐름	4
1.2	네 가지 표현을 혼동하지 않는다	4
2	연구 질문, 가설과 기여 계층	4
2.1	연구 질문	4
2.2	검증 대상 기여	5
2.3	명시적 비주장	5
3	범위와 I/O contract	6
3.1	Setup 및 frame 입력	6
3.2	정량 core 와 champion domain	6
4	Training-only teacher 와 paired 3DGS data	7

4.1 Teacher 가 소유하는 정보	7
4.2 Independent multi-resplat pairing	7
4.3 Privilege boundary	7
5 Patch-to-token encoder 와 내부 relation	8
5.1 Normalization 과 Gaussian token	8
5.2 Patch 기반 latent anchor	8
5.3 내부 relation 과 teacher supervision	9
6 네트워크가 출력하는 response package	9
6.1 Response 의 정확한 의미	9
6.2 Area/mass measure 와 density consistency	9
6.3 Hard attachment 와 mass whitening	10
6.4 Passive Global package	10
6.5 Learned Local residual package	10
6.6 Conditional Local selection	11
7 Wind coupling, response update 와 Gaussian transport	11
7.1 Distributed wind load	11
7.2 Single response update	11
7.3 Renderer transport	12
8 학습 objective 와 단계적 training	12
8.1 Mode column 이 아니라 response 를 맞춘다	12
8.2 Loss family	12
8.3 학습 순서	13
9 왜 기존 방법을 그대로 쓰지 않는가	13
10 Gate, baseline 과 metric	14
10.1 Gate A — Teacher, measure 와 latent representation	14
10.2 Gate B — Learned Global response	15
10.3 Gate C — Local necessity	15
10.4 Gate D — Conditional execution 과 deployment	15
10.5 최소 baseline	15
10.6 지표와 분모	16
11 구현 난이도와 실패 원인	16
12 구현 순서와 claim 축소	17
12.1 Milestone	17
12.2 Claim 경로	18

13 논문 전략	18
13.1 Champion scene 과 quantitative evidence	18
13.2 Venue ladder	18
14 Open decisions 와 freeze policy	19
15 최종 요약	19

1 한눈에 보는 아이디어

1.1 핵심 흐름

Training

연결정보가 있는 mesh 로 여러 재료, 부착과 바람 조건의 reference simulation 을 만든다. 같은 rest surface 를 서로 다른 density, seed 와 view 조건으로 여러 번 3DGS reconstruction 한다. Mesh vertex 와 topology 는 teacher quadrature, same-surface relation 과 response label 을 만드는 데만 사용한다. Student 는 static 3DGS 만 보고 density 가 달라도 비슷한 내부 latent token 을 형성하고, 그 token 에서 passive Global response 와 spatially localized Local residual response 를 예측하도록 학습한다.

Target setup and runtime

Target static 3DGS 와 사용자가 준 material/attachment 를 setup network 에 한 번 넣어 response package 를 cache 한다. 매 frame 에는 바람이 만드는 distributed load 를 package 에 투영하고, Global response 는 항상 적분한다. 현재 load 에서 필요한 Local slot 만 fixed budget 안에서 활성화해 flutter 와 국소 phase detail 을 보완한다. 결과 state 로 Gaussian mean 과 covariance orientation 을 움직여 즉시 렌더한다. Target mesh, target dynamic video, per-target physical fitting 과 persistent edge graph 는 요구하지 않는다.

1.2 네 가지 표현을 혼동하지 않는다

표현	역할
Rendering Gaussian	입력 및 최종 렌더 primitive. 수와 density 는 reconstruction 마다 달라질 수 있다.
Latent response token	Patch evidence 와 global context 를 모으는 network 내부의 normalized slot. 물리 vertex 나 외부 anchor graph 가 아니다.
Response package	Area/mass measure, Global/Local motion field, modal pole 와 damping, selector metadata 를 포함한 setup output.
Dynamic state	Runtime generalized coordinate 와 velocity. Wind load 와 response package 로 deterministic 하게 갱신한다.

2 연구 질문, 가설과 기여 계층

2.1 연구 질문

독립적으로 reconstruction 한 static 3DGS asset [3] 과 명시적인 material, metric scale 및 attachment 만으로, target mesh 나 target motion video 없이 바람에 대한 Global sway 와 필요한 Local flutter response 를 안정적으로 생성할 수 있는가?

핵심 가설은 세 부분이다.

1. Mesh topology 를 inference output 으로 복원하지 않아도, training-only privileged relation 과 multi-resplat consistency 가 patch-to-token encoder 에 same-surface 구조를 내재화할 수 있다.

2. Absolute next deformation 보다 mass-normalized passive response package 를 학습하면 wind, material 과 attachment 변화에 더 controllable 하고 장기 rollout 이 더 안정적이다.
3. Strong fixed-rank Global package 가 놓치는 spatially localized teacher response 가 존재한다면, 그 residual 만 Local slot 으로 학습하고 필요할 때만 실행하여 same-p95 quality-latency Pareto 를 개선할 수 있다.

2.2 검증 대상 기여

1. **MC1 — GS-measure-consistent latent response representation.** Independent GS density/seed/split-merge 변화에도 표면 measure, total wind work 와 response 가 일관되도록 patch 기반 latent token 과 per-Gaussian area/mass ownership 을 response supervision 과 함께 학습한다.
2. **MC2 — topology-privileged, target-mesh-free response distillation.** Training mesh 의 vertex, relation 과 simulation trajectory 를 privileged teacher 로 쓰되, inference 에서는 static GS 로부터 passive response package 를 amortized prediction 한다. Mode column 자체가 아니라 force/impulse/frequency probe 의 physical response 를 맞춘다.
3. **MC3 — wind-residual-driven selective Global-Local response.** 항상 활성화인 Global package 와 Global 이 설명하지 못한 localized Local residual dictionary 를 분리하고, fixed Local budget 에서 현재 wind 가 실제로 excite 하는 slot 만 실행한다.
4. **SYS — renderer-ready Gaussian response execution.** Area-weighted wind coupling, exact attachment, deterministic stable update 와 Gaussian mean/covariance transport 를 하나의 측정 가능한 setup/runtime system 으로 단는다.

Latent token, attention, damped oscillator, virtual-work projection, covariance rotation 각각의 최초성을 주장하지 않는다. Simplicits 와 FreeForm 은 mesh-free reduced simulation 과 Gaussian splat 적용을 이미 다루며 [6, 9], NeuROK 과 LaGSplat 은 learned latent kinematics/dynamics 와 force pullback 을 다룬다 [1, 7]. 방어할 교차점은 **static independent GS** 에서 **amortized wind-response prediction, GS measure/density consistency**, 그리고 **selective Local residual execution** 이다.

2.3 명시적 비주장

- Fully meshless training, relation-free network 또는 arbitrary topology recovery
- Unknown material, thickness, metric scale 와 attachment 를 appearance 만으로 식별
- Engineering-grade stress, support reaction, exact shell constitutive behavior
- Wake, vortex shedding, aerodynamic history 와 two-way fluid-structure interaction
- Self-contact, severe folding, tearing, plastic crease, free flight 와 topology change
- 모든 물체 family 에 대한 universal zero-shot dynamics
- Free-response passivity 만으로 arbitrary time/state-dependent wind 에서도 무조건 bounded 하다는 보장
- Profiler 와 matched-p95 evidence 전의 real-time 또는 speedup claim

정확한 표현은 **target-mesh-free inference without a persistent physical adjacency graph** 다. Encoder 내부 patch, attention affinity 와 transient neighborhood 까지 없다는 뜻은 아니다.

3 범위와 I/O contract

3.1 Setup 및 frame 입력

$$\mathcal{I}_{\text{setup}} = (\mathcal{G}^0, \vartheta_{\text{metric}}, \vartheta_{\text{mat}}, \mathcal{C}_{\text{attach}}, \vartheta_{\text{aero}}, \vartheta_{\text{domain}}), \quad (1)$$

여기서 $\mathcal{G}^0 = \{\mu_i^0, \Sigma_i^0, \alpha_i, c_i\}_{i=1}^N$ 는 rest static GS 다. $\vartheta_{\text{metric}} = (L_0, A_{\text{ref}}, M_{\text{ref}})$ 는 target 에서 제공하는 positive world-length/area/mass reference 이며, ϑ_{mat} 는 mass/stiffness/damping preset, $\mathcal{C}_{\text{attach}}$ 는 hard attachment mask 또는 geometric region 이다. ϑ_{aero} 는 bounded traction preset 이고 $\vartheta_{\text{domain}}$ 은 허용 geometry, wind, timestep/frequency 및 OOD envelope 를 소유한다. 이 typed physical metadata 를 모르는 target 은 core input 밖이며 appearance 에서 역추론하지 않는다. Appearance 는 renderer 가 소유하며 physics encoder 는 opacity, covariance 와 low-order appearance cue 중 development 에서 허용한 subset 만 사용한다. Texture memorization 을 막기 위해 appearance randomization ablation 을 둔다.

Frame 입력은

$$\mathcal{I}_t = (W_t(\cdot), \Delta t, s_{t-1}, \mathcal{P}), \quad (2)$$

이다. W_t 는 prescribed wind field, s_{t-1} 는 cached generalized state, $\mathcal{P}$ 는 setup response package 다. Package 는 rest GS 와 모든 target-allowed physical metadata 의 identity/hash 및 runtime payload 를 소유하므로 frame API 가 teacher mesh 나 별도 hidden state 를 조회하지 않는다. Target dynamic RGB/video 나 target mesh state 를 재입력하지 않는다.

3.2 정량 core 와 champion domain

축	정량 core	Gate 후 확장
Geometry	flat-rest single-layer strip, rectangular flag	triangular pennant, simple curtain panel, mild curved silhouette
Attachment	한 edge 또는 작은 declared patch 의 hard clamp	dev 에 포함한 제한적 attachment family
Material	2-3 known isotropic presets	preset interpolation; arbitrary inference 금지
Wind	steady, start/stop, sinusoidal, spatial/traveling gust	unseen composition 과 제한적 field perturbation
Motion	small-to-moderate deformation, one-way wind	더 큰 rotation 은 confidence/OOD 와 함께 qualitative
Rendering	mean + covariance rotation, degree-0 physics evaluation	higher SH/frame transport 는 paper-stage

Champion scene 은 사후에 성공 사례만 고르는 뜻이 아니다. 위 domain 과 failure criteria 를 development 에서 동결하고, 그 안에서 Global sway, free-edge flutter 와 traveling gust 가 잘 드러나는 3-5 개 hero scene 을 선택한다. 같은 범위의 object-disjoint 작은 quantitative suite 와 실패 장면도 함께 공개한다.

4 Training-only teacher 와 paired 3DGS data

4.1 Teacher 가 소유하는 정보

Teacher mesh simulator 는 vertex/element connectivity, surface quadrature, material, attachment 와 prescribed wind 를 소유한다. Reference trajectory 에는 canonical surface sample 에서의 position, displacement, velocity, optional normal, applied traction 와 external work 를 저장한다. Teacher refinement 와 timestep convergence 가 확인되기 전에는 student training 을 시작하지 않는다.

Mesh vertex 를 모두 supervision 에 사용하는 것은 유용하지만, **vertex 하나를 latent anchor 하나와 일대일 대응시키지 않는다**. Vertex 수와 tessellation 은 simulator discretization 선택이기 때문이다. 각 vertex 는 area-weighted dense teacher sample 로 사용하고, fixed/capped latent token 은 이 sample 을 soft aggregation 한 response carrier 로 학습한다. 필요하면 공통 canonical surface probe 로 remap 해 서로 다른 teacher mesh resolution 도 같은 evaluation space 에서 비교한다.

4.2 Independent multi-resplat pairing

같은 rest mesh 를 서로 다른 camera subset, initialization seed, densification schedule 과 target density 로 독립 reconstruction 한다. 단순히 한 GS 를 split/duplicate 한 것은 independent variant 로 세지 않는다. 같은 source object 의 모든 mesh, GS variant, material 과 wind sequence 는 하나의 train/dev/test group 에 둔다.

권장 최소 단계는 다음과 같다.

1. **K0 smoke:** strip 1 개와 flag 1 개, material 1 개, independent GS 2 개, impulse 와 step wind.
2. **K1 feasibility:** narrow family 의 object-grouped train/dev/test, object 당 2-3 GS density/seed variant, 2-3 material preset 과 네 probe family.
3. **Paper evidence:** K1 Gate 가 통과한 뒤에만 hero scene, real reconstruction 과 broader silhouette 를 추가한다.

Core probe 는 short impulse, step-on/off, log-chirp 또는 multi-sine, traveling Gaussian gust 다. Probe peak 와 duration 은 asset 별로 조정하지 않고 development 에서 domain-wide freeze 한다.

4.3 Privilege boundary

정보	Training	Target inference
Mesh vertex/connectivity	teacher simulation 과 auxiliary label 에 사용	금지
Mesh-GS correspondence	loss/evaluation remap 에 사용	금지
Static GS attributes	student 입력	필수
Physical metadata	명시 입력	명시 입력
Wind program	teacher force 와 student rollout	runtime 입력

정보	Training	Target inference
Dynamic target video	qualitative evaluation 에 만 선택적	방법 입력으로 금지
Persistent edge/triangle graph	teacher 내부에만 존재	생성·저장·소비 금지

Forward API 가 forbidden field 를 받지 않는지, batch 가 source-object split 을 넘나들지 않는지와 checkpoint 가 test normalization 을 보지 않았는지를 manifest 와 automated leakage test 로 확인한다.

5 Patch-to-token encoder 와 내부 relation

5.1 Normalization 과 Gaussian token

Object center o , positive length scale L_0 와 attachment-defined canonical cue 를 사용해 position/covariance 를 normalize 한다.

$$\hat{\mu}_i = \frac{\mu_i^0 - o}{L_0}, \quad \hat{\Sigma}_i = \frac{\Sigma_i^0}{L_0^2}, \quad g_i = E_{\text{gs}}(\hat{\mu}_i, \hat{\Sigma}_i, \alpha_i, c_i, b_i, \vartheta_{\text{mat}}). \quad (3)$$

b_i 는 attachment indicator 또는 distance cue 다. Proper rigid transform 과 scale 변화에 대한 canonicalization/equivariance fixture 를 별도로 둔다. Severe symmetry 에서 canonical frame 이 모호하면 confidence reject 또는 sign-invariant feature 를 사용한다.

5.2 Patch 기반 latent anchor

입력 GS 를 normalized space 의 overlapping local patch 로 나누고, 각 patch evidence 를 fixed/capped K 개의 latent query 가 density-normalized cross-attention 으로 읽는다 [2]. 개념적으로

$$h_k^{\text{loc}} = \frac{\sum_i w_{ki} g_i}{\sum_i w_{ki} + \epsilon_w}, \quad w_{ki} \geq 0, \quad (4)$$

이며 실제 attention 은 learnable key/query 와 covariance/tangent cue 를 함께 쓸 수 있다. Patch 는 계산 receptive field 이지 물리 element 가 아니다. h_k 를 “latent anchor” 라고 부르더라도 그 좌표와 edge 를 deployment package 에 내보내지 않는다.

Patch-only 로는 멀리 떨어진 attachment 와 free edge 의 관계를 놓칠 수 있으므로, local aggregation 뒤 K token 간 global self-attention 또는 pooled object token 을 사용한다. 즉 사용자가 원하는 “patch 기반이되 필요하면 전체 3DGS 도 본다” 를 **local evidence first, global context second** 로 구현한다.

Token 을 얻은 뒤에는 원래 Gaussian feature 가 token 과 object context 를 다시 읽는 query decoder 를 사용한다. 이 decoder 는 input permutation 에 equivariant 하다.

$$y_i = D_{\text{query}}(g_i, \{h_k\}_{k=1}^K, h_{\text{obj}}), \quad i = 1, \dots, N.$$

여기서 y_i 는 Gaussian 별 area/mass, normal/validity 와 Global/Local response-field row 를 생성한다. 따라서 fixed token 수가 variable Gaussian 수로 되돌아가는 readout 은 명시적이지만, Gaussian 사이 physical edge 나 persistent graph 를 만들지는 않는다.

5.3 내부 relation 과 teacher supervision

Token relation A_{kl} 는 relative geometry, attachment context 와 learned token feature 로 계산되고 같은 forward pass 안에서만 소비된다. Training mesh 의 same-surface, geodesic 및 layer label 은 attention bias, contrastive retrieval 또는 teacher relation probe 의 auxiliary loss 로 사용할 수 있다. 그러나 A_{kl} 를 physical edge 로 threshold 해 solver 에 전달 하지 않는다.

Latent token 이 의미 있는지는 다음 diagnostic 으로 확인한다.

- independent GS variant 사이 token coverage 와 response consistency
- token collapse/duplicate 비율과 surface coverage
- same-surface neighbor retrieval 및 close-layer shortcut error
- attachment/free-edge query 에 대한 global-context ablation
- internal relation 을 제거한 capacity-matched direct-set baseline 과 response 차이

Diagnostic 이 motion gain 으로 이어지지 않으면 latent-anchor 자체를 기여로 주장하지 않는다.

6 네트워크가 출력하는 response package

6.1 Response 의 정확한 의미

Student setup network F_θ 는 deformed Gaussian 이나 next pose 를 출력하지 않는다. 먼저 target-allowed immutable runtime payload 를

$$\mathcal{D}_{\text{rt}}^0 = (\text{id/hash}(\mathcal{G}^0), \mathcal{G}^0, \vartheta_{\text{metric}}, \vartheta_{\text{mat}}, \mathcal{C}_{\text{attach}}, \vartheta_{\text{aero}}, \vartheta_{\text{domain}})$$

로 둔다. Teacher mesh 에서 복사한 normal, validity, area 또는 correspondence 는 여기에 들어갈 수 없다.

$$\begin{aligned} \mathcal{P} &= \text{Pack}(\mathcal{D}_{\text{rt}}^0, F_\theta(\mathcal{I}_{\text{setup}})) \\ &= \left(\mathcal{D}_{\text{rt}}^0, a, m, n^0, \gamma_{\text{valid}}, \gamma_{\text{ori}}, B_G, \Omega_G, Z_G, \{B_{L,k}, \Omega_{L,k}, Z_{L,k}, c_k\}_{k=1}^{K_L}, B_R \right). \end{aligned} \quad (5)$$

여기서 $a_i \geq 0$ 와 $m_i \geq 0$ 는 Gaussian 별 surface-area 및 mass quadrature, B_G 는 Global translational response field, $B_{L,k}$ 는 Local slot field, Ω 와 Z 는 positive modal frequency 와 damping, $n_i^0, \gamma_{\text{valid},i}, \gamma_{\text{ori},i}$ 는 target GS 에서 frozen model 이 예측하거나 versioned co-variance rule 로 계산한 rest surface payload 다. c_k 는 support/confidence metadata 다. $B_R = (B_{R,G}, \{B_{R,L,k}\})$ 를 쓰는 branch 에서는 각 angular field 가 같은 이름의 translational coordinate 를 공유한다. 이를 쓰지 않는 core branch 는 transported means 에서 계산하는 versioned local-affine normal update 를 package 에 기록한다. 두 branch 중 하나를 R0 에서 freeze 하고 asset 별로 바꾸지 않는다. Network inference 는 setup 에서 한 번 수행하고 package 를 cache 한다.

Runtime 의 frame response 는 이 package 와 current wind 로 계산한 generalized acceleration/velocity increment 다. 따라서 “response 를 출력한다” 는 말은 **setup network** 가 **causal force-to-motion operator** 를 **parameterize** 하고, **frame evaluator** 가 그 **operator** 의 **response increment** 를 계산한다는 뜻이다.

6.2 Area/mass measure 와 density consistency

Gaussian 은 texture 와 reconstruction error 에 따라 비균일하게 배치되므로 opacity 나 primitive count 를 surface area 로 간주하지 않는다. Positive raw logits 를 normalize 해

declared total area 와 mass 를 보존한다.

$$a_i = A_{\text{ref}} \frac{\text{softplus}(\xi_i^a) + \epsilon_a}{\sum_j (\text{softplus}(\xi_j^a) + \epsilon_a)}, \quad m_i = M_{\text{ref}} \frac{\text{softplus}(\xi_i^m) + \epsilon_m}{\sum_j (\text{softplus}(\xi_j^m) + \epsilon_m)}. \quad (6)$$

$A_{\text{ref}}, M_{\text{ref}} > 0$ 는 target-side typed metric/material contract 가 소유하고 package 에 그 값과 단위를 hash 한다. Teacher mesh 값으로 target package 를 채우거나 asset 별 사후 보정하지 않는다. Surface split/merge 에서 child ownership 합이 parent ownership 과 같으면 constant-cell force/work 는 보존된다. Independent reconstruction 에서는 common teacher probe 에서 total area, work 와 response dispersion 을 측정한다.

6.3 Hard attachment 와 mass whitening

Raw response field $\tilde{B}$ 는 attachment row 를 exact zero projection 한 뒤 mass metric 으로 whitening 한다.

$$B_c = P_{\text{attach}} \tilde{B}, \quad B = B_c (B_c^\top M_x B_c)^{-1/2}, \quad M_x = \text{diag}(m_i I_3). \quad (7)$$

그러면 attached row 는 수치오차 안에서 0 이고 $B^\top M_x B = I$ 다. Gram eigenvalue 가 floor 아래면 rank 를 줄이거나 package 를 reject 한다. Attachment 를 network input 에도 넣어 response shape 와 pole 을 조건화하되 hard exactness 는 learned penalty 에 맡기지 않는다.

6.4 Passive Global package

Global coordinate q_G 는 다음 mass-normalized damped response 를 따른다.

$$\ddot{q}_G + 2Z_G \Omega_G \dot{q}_G + \Omega_G^2 q_G = Q_G, \quad u_G = B_G q_G. \quad (8)$$

Frequency 와 damping 은 positive parameterization 으로 만들고 B_G 는 attachment projection 과 whitening 을 통과한다. Free response 에서는 energy 가 감소하는 passive LTI core 가 된다. Runtime 은 explicit Euler 보다 independent damped oscillator 의 exact zero-order-hold update 또는 stable implicit update 를 사용한다. State-dependent wind 가 외부 에너지를 공급하므로 forced rollout 에는 별도 force cap, timestep/frequency envelope 와 long-horizon stress test 가 필요하다.

Full dense M, C, K 나 nonlinear $M(q), C(q), V(q)$ 를 V0 output 으로 두지 않는다. 이들은 latent gauge 와 conditioning 을 어렵게 하고 NeuROK/LaGSplat 의 비선형 latent solver 범위와 겹친다. Non-proportional damping 이나 mode coupling 이 반복적으로 필요한 경우에만 positive block extension 을 검토한다.

6.5 Learned Local residual package

Local 은 teacher full motion 을 그대로 다시 학습하지 않는다. Frozen Global response 가 설명한 component 를 빼고

$$r_L^* = r_{\text{teacher}} - r_G^*, \quad B_{L,k} = \text{whiten} \left[(I - B_G B_G^\top M_x) P_{\text{attach}} \tilde{B}_{L,k} \right] \quad (9)$$

로 정의한 complementary residual 만 학습한다. r 는 canonical surface probe 의 time/frequency response 이며 개별 eigenmode column 이 아니다. 이 정의가 Global/Local double counting 과 sign/permutation/degenerate-mode gauge 문제를 줄인다.

Local 은 처음부터 함께 학습하지 않는다.

1. Global-only 를 overfit 하고 narrow-domain held-out response 를 확인한다.

2. Teacher residual atlas 와 high-rank Global sweep 으로 Local 필요성을 판정한다.
3. Oracle/always-on Local 이 실제 이득을 보인 뒤 Local package head 를 학습한다.
4. 마지막에 conditional selector 와 temporal switching 을 붙인다.

6.6 Conditional Local selection

각 Local slot 의 generalized load 와 predicted response energy 로 inexpensive score 를 계산한다. 개념적 quasi-static score 는

$$\eta_k(t) = \frac{\|Q_{L,k}(t)\|_2^2}{\omega_{L,k}^4 + \epsilon_\eta} + \lambda_g \chi_k(\nabla W_t, h_k, c_k), \quad (10)$$

이며 χ_k 는 작은 learned residual-risk term 이거나 0 일 수 있다. Fixed top- K_A , deterministic tie-break, minimum dwell, fade 와 persistent state 로 pop 을 막는다. Global 은 항상 활성화되고 Local 만 budgeted 된다. Selection overhead 와 all-slot load projection 이 전체 비용을 지배하면 selective speed claim 은 철회한다.

7 Wind coupling, response update 와 Gaussian transport

7.1 Distributed wind load

Current relative velocity 와 oriented normal 에서 bounded traction τ_i^t 를 계산하고 learned measure 를 곱한다.

$$F_i^t = a_i \tau(v_{\text{wind},i}^t - v_i^t, n_i^t; \vartheta_{\text{aero}}), \quad Q_S^t = B_S^\top F^t, \quad (11)$$

여기서 S 는 Global 과 selected Local field 의 집합이다. Traction 과 total force 를 구분해 area 를 두 번 곱하지 않는다. Opacity 를 area substitute 로 쓰지 않으며, floater/background 와 close two-sided layer 가 load 를 받지 않도록 validity/confidence 와 domain reject 를 둔다.

Rest normal 은 covariance-derived tangent cue, learned orientation confidence 와 training-only teacher supervision 을 사용한다. Current normal 은 angular response 또는 local affine approximation 으로 갱신한다. Gaussian covariance 의 가장 작은 축이 물리 surface normal 과 항상 같다고 가정하지 않으며, orientation confidence 가 낮은 target 은 quantitative set 에서 reject/fallback 한다.

7.2 Single response update

Global 및 admitted Local coordinate 를 하나의 state tuple 로 유지한다. 각 frame 은 다음 순서를 정확히 한 번 수행한다.

1. 이전 state 에서 current mean, velocity, orientation 과 load site 를 복원한다.
2. 모든 required load site 의 bounded wind force 를 한 번 평가한다.
3. Global load 와 Local candidate score 를 계산하고 fixed budget 을 admit 한다.
4. Global 과 selected Local damped response 를 같은 Δt 로 한 번 update 한다.
5. Local activation/deactivation fade 를 적용하되 hidden re-solve 는 하지 않는다.
6. 최종 response field 로 Gaussian 을 transport 하고 frame trace 를 기록한다.

Network 가 매 frame absolute pose 를 다시 생성하지 않기 때문에 arbitrary wind program 의 causal control 과 long-horizon stability 를 독립적으로 검증할 수 있다.

7.3 Renderer transport

최소 translational transport 는

$$\mu_i^t = \mu_i^0 + B_{G,i} q_G^t + \sum_{k \in S_t} B_{L,k,i} q_{L,k}^t. \quad (12)$$

Flag-like disk Gaussian 은 normal rotation 이 시각적으로 중요하므로 같은 generalized coordinate 를 사용하는 small angular field B_R 를 허용한다. Rotation 은 exponential map 으로 적용하고 covariance eigenvalue 는 보존한다. Scale/shear, nonlinear deformation-gradient transport 와 higher-order SH rotation 은 translation/rotation V0 가 시각적으로 실패한 증거가 있을 때만 추가한다.

Attachment Gaussian 의 displacement/angular row 는 exact zero 다. Identity, proper-rigid, covariance SPD, finite output 와 visual pop fixture 를 통과해야 한다. Transport 실패 frame 을 quality metric 에서 제거하지 않고 method failure denominator 에 유지한다.

8 학습 objective 와 단계적 training

8.1 Mode column 이 아니라 response 를 맞춘다

Teacher eigenmode 는 sign, order 와 repeated-eigenvalue subspace rotation 이 비유 일하다. 따라서 mode-by-mode L_2 를 primary label 로 쓰지 않는다. Random impulse, distributed wind 와 frequency probe p 에 대해 canonical surface 에서

$$\mathcal{L}_{\text{resp}} = \sum_p (\lambda_x \|u_p - u_p^*\|_{W_A}^2 + \lambda_v \|v_p - v_p^*\|_{W_M}^2 + \lambda_f \mathcal{E}_{\text{FRF}}(p) + \lambda_T \mathcal{E}_{\text{rollout}}(p)) \quad (13)$$

를 최소화한다. W_A, W_M 는 teacher surface area/mass measure 다. FRF loss 는 amplitude 와 phase 를 함께 보고, time loss 는 position 보다 velocity 를 primary 로 둔다.

8.2 Loss family

Loss/constraint	목적
Response rollout	Teacher displacement/velocity 와 long-horizon recovery 를 physical space 에서 맞춘다.
Frequency/phase	Global sway 와 Local flutter band 의 amplitude, phase 와 log-PSD 를 맞춘다.
Measure ownership	Total area/mass, work 와 load integral 을 teacher quadrature 에 맞춘다.
Multi-resplat consistency	같은 source surface 의 independent GS variants 가 common probe 에서 같은 package response 를 내게 한다.
Latent relation auxiliary	Same-surface retrieval 과 close-layer shortcut 을 줄이 되 relation graph 를 output 으로 만들지 않는다.
Global/Local ownership	Local 이 fixed Global residual 만 설명하고 중복 energy 를 최소화한다.
Selection sparsity/continuity	Fixed budget, turnover 와 activation pop 을 제한한다.

Loss/constraint	목적
Exact construction	Positive pole/damping, attachment zero, mass whitening 은 penalty 가 아니라 layer 로 보장한다.

Total objective 는

$$\mathcal{L} = \mathcal{L}_{\text{resp}} + \lambda_{\text{measure}}\mathcal{L}_{\text{measure}} + \lambda_{\text{pair}}\mathcal{L}_{\text{pair}} + \lambda_{\text{rel}}\mathcal{L}_{\text{rel}} + \lambda_{\text{local}}\mathcal{L}_{\text{local}} + \lambda_{\text{switch}}\mathcal{L}_{\text{switch}}. \quad (14)$$

정확한 weight 는 canonical method equation 이 아니라 development config 다. Search range, selection metric 과 final value 를 train/dev/test lifecycle 에 맞춰 freeze 하고 run hash 에 넣는다.

8.3 학습 순서

1. **Stage T0:** teacher convergence, mesh-GS correspondence 와 unit/force sign 검증
2. **Stage T1:** area/mass measure 와 patch-to-token representation pretraining
3. **Stage T2:** single-object/single-GS Global overfit 및 long rollout
4. **Stage T3:** multi-resplat paired Global training 과 narrow-domain held-out 검증
5. **Stage T4:** frozen Global residual 로 always-on Local package 학습
6. **Stage T5:** conditional Local selection 과 temporal switching 학습
7. **Stage T6:** limited joint fine-tuning; attachment/passive construction 은 항상 유지

Direct image/perceptual render loss 는 response core 가 성공한 뒤 optional fine-tuning 으로만 검토한다. 처음부터 renderer loss 를 넣으면 motion Jacobian 과 physical response 가 틀려도 영상만 맞는 shortcut 이 생길 수 있다.

9 왜 기존 방법을 그대로 쓰지 않는가

방법	그대로 적용할 때의 핵심 공백	본 방법이 검증하려는 차이
LaGSplat [7]	대상 물체의 own dynamic video 에서 per-system latent Lagrangian 과 GS decoder 를 식별한다. 관측 되지 않은 mode 와 force scale 이 제한된다.	Target dynamic video/fine-tune 없이 static GS 에서 multi-object amortized wind response 를 예측하고 systematic teacher excitation 으로 Local response 를 제공한다.
NeuROK [1]	Static mesh 에서 plausible kinematic manifold 를 예측하고 generic latent Lagrangian ODE 를 푼다. Exact material-specific wind response 가 학습 목표가 아니다.	Pose manifold 보다 known wind/material/attachment 의 force-to-motion response 를 직접 증류한다.

방법	그대로 적용할 때의 핵심 공백	본 방법이 검증하려는 차이
Simplicits [6]	Representation-agnostic reduced simulation 이지 만 object 별 neural field fitting 과 elastic energy evaluation 이 필요하다.	Narrow-domain amortized static-GS response compiler 와 density consistency, selective Local Pareto 를 검증한다.
FreeForm [9]	Particle/RKPM 기반 skinning eigenmode 와 generalized eigensystem 을 setup 한다.	Target persistent particle physics graph 없이 student package 를 prediction 하고 distributed wind response 를 학습 한다.
Gaussian Swaying [11]	Surface-based GS aerodynamics 를 직접 구성 하지만 learned measure-invariant response distillation 과 selective Local 이 없다.	Same wind task 의 direct baseline 으로 area/response consistency 와 quality-latency 차 이를 검증한다.
이전 explicit scaffold	Anchor edge/triplet 과 structural/reduced package 가 해석 가능하지만 target topology extraction 과 solver contract 가 복잡하다.	내부 relation 만 유지하고 외부 scaffold 를 제거하되 response 정확 도와 안정성을 teacher/old baseline 에 대해 검증한다.

PhysGaussian 과 FastPhysGS 는 Gaussian 의 물리 transport/실행 baseline 이고 [10, 5], DiffWind 는 video-conditioned wind reconstruction 과 particle/grid physics 계열의 비교 축이다 [4]. Neural Modes 의 nonlinear modal-subspace 학습은 response representation 선행축으로 비교하되, 본 방법의 density-aware distributed-load 와 conditional Local claim 을 그 구성요소의 최초성으로 포장하지 않는다 [8].

입출력만 GS 로 바꾼 NeuROK/LaGSplat adapter 는 novelty 가 아니라 failure baseline 이다. Transformer, latent token, $B^\top F$, damped oscillator 와 attention 자체도 method claim 이 아니다.

10 Gate, baseline 과 metric

10.1 Gate A — Teacher, measure 와 latent representation

- **Gate A_T , teacher prerequisite:** mesh/time refinement 가 canonical velocity, tip trajectory 와 dominant frequency 에서 수렴하고, single object Global package 가 training sequence 를 overfit 하며 긴 free decay 에서 발산하지 않는다.
- **Gate A_M , measure:** independent GS density/seed variant 의 total area, work 와 common-probe response dispersion 이 dev-frozen tolerance 안에 있다.
- **Gate A_L , latent representation:** capacity-matched direct-set encoder 보다 latent token/relation 이 response 또는 density robustness 를 개선한다.

Gate A_T 실패는 learned-response pipeline 을 막는다. Gate A_M 만 실패하면 density claim 을 철회하고 fixed reconstruction family 로 제한할 수 있다. Gate A_L 만 실패하면 latent-anchor contribution 을 삭제하고 direct-set response model 로 진행할 수 있다. 어느 경우에

도 dataset 을 무작정 늘리지 않는다.

10.2 Gate B — Learned Global response

Object-disjoint narrow-domain test 에서 Global package 가 direct next-deformation network 와 fixed mean/nearest-response baseline 보다 velocity, phase, material ordering 과 long rollout 에서 유의하게 낮거나 동등하면서 더 stable 해야 한다. Test threshold 는 dev 에서 freeze 하고 result 를 본 뒤 바꾸지 않는다. 실패하면 response-package hypothesis 를 중단하거나 per-family compiler 로 claim 을 축소한다.

10.3 Gate C — Local necessity

Strong Global rank/capacity sweep 과 Global+teacher/oracle Local residual 을 same latency 또는 same active-DOF 조건에서 비교한다. Local 은 다음이 모두 참일 때만 core 로 남긴다.

- Traveling/local gust 에서 residual 이 teacher/mapping noise 보다 크고 여러 object/GS variant 에서 반복된다.
- Residual 이 공간적으로 localized 되고 target temporal band 의 amplitude/phase/PSD 에 영향을 준다.
- Global rank 를 늘리는 것보다 oracle/always-on Local 이 matched-p95 에서 의미 있는 품질 이득을 낸다.

실패하면 paper 를 measure-consistent Global response 로 축소한다.

10.4 Gate D — Conditional execution 과 deployment

Conditional Local 이 always-on Local 의 quality 를 dev-frozen allowance 안에서 유지하면서 actual p95 latency 를 개선하고, fixed high-rank Global 및 이전 explicit scaffold 의 frozen Pareto envelope 밖의 점을 만들어야 한다. Memory 와 throughput 은 mandatory secondary diagnostic 으로 함께 보고한다.

$$\begin{aligned}
 E_{\text{cond}} - E_{\text{always}} &\leq \epsilon_{E,\text{keep}}, \\
 L_{\text{cond}} - L_{\text{always}} &\leq -\delta_{L,\text{always}}, \\
 E_{\text{cond}} &\leq E_{\mathcal{B}}(L_{\text{cond}}) - \delta_E, \\
 \text{or } L_{\text{cond}} &\leq L_{\mathcal{B}}(E_{\text{cond}}) - \delta_{L,\mathcal{B}}.
 \end{aligned} \tag{15}$$

여기서 error 는 dev 에서 정한 primary response metric, latency 는 actual p95 다. $\mathcal{B}$ 는 test 전에 동결한 모든 fixed high-rank Global 과 explicit-scaffold baseline 의 non-dominated Pareto set 이고, $E_{\mathcal{B}}(L)$ 와 $L_{\mathcal{B}}(E)$ 는 각각 그 set 의 dev-frozen matched-axis envelope 다. $\epsilon_{E,\text{keep}}, \delta_{L,\text{always}}, \delta_E, \delta_{L,\mathcal{B}} > 0$ 와 envelope interpolation/tolerance 를 test open 전에 freeze 한다. Selection overhead 가 이득을 상쇄하면 conditional claim 을 철회하고 always-on Local 또는 Global-only 로 끝낸다.

10.5 최소 baseline

1. Converged high-resolution mesh teacher/reference
2. 이전 explicit scaffold 와 optimized full/same-resolution physical baseline
3. Direct static-GS $\rightarrow$ next deformation predictor

4. Capacity-matched direct static-GS $\rightarrow$ Global response package without latent relation supervision
5. Global rank/capacity sweep
6. Global + oracle/always-on Local
7. Global + conditional learned Local
8. Equal-splat/opacity weight, no multi-resplat consistency, no relation auxiliary ablations
9. 공개 코드와 task adaptation 이 가능한 direct GS physics/wind 방법 1-2 개

NeuROK/LaGSplat 처럼 공개 implementation 이 없거나 큰 adaptation 이 필요한 방법은 conceptual comparison 과 small adapter baseline 의 범위를 명시하고, 무리한 full reproduction 을 P0 blocker 로 두지 않는다.

10.6 지표와 분모

Primary motion metric 은 per-sequence mass/area-weighted velocity error, displacement/tip trajectory, amplitude/phase 와 target-band log-PSD 다. Rendering 은 silhouette, temporal flicker 와 qualitative split-screen 을 보조로 둔다. System metric 은 setup time, package memory, network/force/update/transport/render 각각의 p50/p95/p99 와 throughput 이다.

각 source object 를 independent outer cluster 로 두고, 그 안의 GS package 와 wind sequence 를 nested paired comparison 한다. Declared OOD 는 실행 전 입력 조건으로만 제외한다. In-envelope NaN, invalid covariance, package rank failure, rollout divergence 와 fallback-cap 초과는 고정 denominator 의 method failure 다. Low object count 에서는 descriptive interval 과 all-object effect 를 보고하고 accept-ready population claim 을 하지 않는다.

11 구현 난이도와 실패 원인

위험	왜 어려운가	조기 판정/대응
Teacher-GS correspondence	Independent reconstruction 의 primitive 는 material point 가 아니다.	K0 에서 canonical surface probe transport 와 force sign 부터 확인한다.
Density invariance	Gaussian count/opacity 가 바뀌면 naive mass/force 가 달라진다.	Multi-resplat pair, area/mass ownership 과 equal-weight ablation 을 먼저 실행한다.
Static identifiability	같은 geometry 도 material/attachment 가 다르다면 response 가 다르다.	물리 metadata 를 입력하고 supported preset 만 주장한다.
Latent collapse	Fixed token 이 같은 patch 를 중복하거나 teacher tessellation 을 암기할 수 있다.	Coverage/duplicate probe, density pair, object-group split 과 token-free baseline 을 둔다.

위험	왜 어려운가	조기 판정/대응
Response gauge	Mode sign/order/subspace 가 비 유일하다.	Mode column 대신 physical probe response 를 학습한다.
Local leakage	Local 이 Global sway 를 다 시 학습해 selector 의미가 사라질 수 있다.	Frozen Global residual, complement projection 과 always-on oracle Gate 를 사용한다.
Autoregressive drift	Small one-step error 가 phase 와 energy drift 로 누적된다.	Passive pole parameterization, stable update, multi-step/free-decay loss 와 stress test 를 사용한다.
Renderer mismatch	Mean 은 맞아도 covariance/normal 이 틀리면 blur 와 wrong wind 가 생긴다.	Translation kill 후 angular transport 와 identity/rigid/SPD fixture 를 추가한다.
Generalization failure	Narrow data 에서 network 가 shape/template 을 암기 할 수 있다.	Source-object split, held-out aspect/silhouette, no fine-tune 와 failure regime 를 공개한다.
No speed gain	Small modal solve 보다 all-GS projection/transport 가 지 배할 수 있다.	Component profiler 후에만 selective Local speed headline 을 유지한다.

구현 난이도의 핵심은 Transformer layer 를 작성하는 것보다 teacher data contract, multi-resplat pairing, response identifiability 와 held-out evidence 다. Champion domain 으 로 범위를 좁히면 성공 확률은 높아지지만, per-scene fitting 으로 바뀌지는 않는다.

12 구현 순서와 claim 축소

12.1 Milestone

1. **R0 Contract:** typed I/O, privilege boundary, units, domain 와 failure denominator 동결
2. **R1 Teacher smoke:** strip/flag reference convergence, mesh-GS remap, force/-transport fixture
3. **R2 Global overfit:** single object/package response overfit, passive rollout, exact attachment
4. **R3 Measure consistency:** paired independent GS density/seed invariance 와 Gate A
5. **R4 Narrow-domain Global:** object-disjoint held-out Global response 와 Gate B
6. **R5 Local necessity:** residual atlas, high-rank Global, oracle/always-on Local 과 Gate C
7. **R6 Conditional Local:** fixed-budget selection, persistent state/fade 와 Gate D

8. **R7 Renderer/paper:** covariance rotation, champion scene, baseline 과 ablation, claim 과 venue freeze

R1-R2 가 실패하면 dataset 확대나 Local 구현을 하지 않는다. R3 가 실패하면 density-invariant claim 을 철회하거나 fixed reconstruction family 로 줄인다. R4 가 실패하면 target-mesh-free amortized claim 을 중단한다. R5 가 실패하면 Global-only 논문으로 축소하고, R6 가 실패하면 always-on Local 로 남긴다.

12.2 Claim 경로

Measure	Global	Local	허용 claim
Pass	Pass	Pass	Measure-consistent static-GS Global-Local wind-response distillation
Pass	Pass	Fail	Measure-consistent passive Global wind-response package
Fail	Pass	Pass	Fixed-reconstruction-family learned response; density claim 철회
Pass	Fail	-	Pivot 중단 또는 explicit scaffold/teacher solver 로 복귀
Fail	Fail	-	Learned response 방법 중단

이전 explicit scaffold 는 버리는 코드가 아니라 teacher/oracle, interpretable baseline 과 fallback research route 다. 새 방향이 Gate 를 통과하지 못하면 archive 의 설계를 근거와 함께 복원할 수 있다.

13 논문 전략

13.1 Champion scene 과 quantitative evidence

Hero scene 은 soft strip step/recovery, stiff strip impulse/chirp, rectangular flag traveling gust, 동일 flag 의 low/high-density independent GS 를 기본으로 한다. 여기에 frozen model 의 pennant 또는 real flag 를 qualitative transfer 로 추가할 수 있다.

소수 champion scene 은 시각적 설득을 담당하고, novelty evidence 는 별도의 object-disjoint narrow-domain table, multi-resplat robustness, matched-p95 Global/Local Pareto 와 failure case 가 담당한다. 지원 domain 밖의 모든 상황을 해결할 필요는 없지만, 지원 domain 을 결과 후에 소급 정의해서도 안 된다.

13.2 Venue ladder

현재 animation/simulation 중심 framing 의 현실적 첫 목표는 SCA full paper 를 통한 Computer Graphics Forum 게재다. Global/Local quality-latency 와 broader visual system evidence 가 강하면 Eurographics 의 CGF 경로 또는 TVCG 를 검토한다. Measure invariance 와 response distillation 이 일반 원리로 닫히고 comprehensive validation 이 모이면 SIGGRAPH 와 SIGGRAPH Asia 의 dual track 또는 TOG 가 상한이다.

AI 저널을 목표로 바꾸려면 champion-scene system 이 아니라 broad object-disjoint operator learning, sampling invariance, OOD 와 learning-theoretic/architectural insight 가 논문의 중심이 되어야 한다. 현재 scope-control 목표에는 CG route 가 더 적합하다.

14 Open decisions 와 freeze policy

다음은 구현 실험에서 선택하되 test 전에 freeze 할 항목이다.

- Latent token 수 K , patch proposal 과 global attention depth
- Global rank/pole 수, Local slot 수와 slot 당 rank
- Area/mass head 공유 여부와 total ownership convention
- Response loss 의 time/frequency weight 와 rollout horizon
- Local residual decomposition 의 exact filter/projection rule
- Selector score 의 analytic-only 대 learned residual-risk 비교
- Covariance rotation head 도입 시점과 higher-order appearance policy

하지만 다음은 method identity 라서 R0 전에 고정한다.

- Target forward 에 mesh/connectivity/correspondence 가 들어가지 않는다.
- Network output 은 absolute deformation 이 아니라 cached response package 다.
- Mesh vertex 는 dense teacher sample 이지 one-to-one inference token 이 아니다.
- Global 은 항상 활성화이고 Local 은 frozen Global residual 만 소유한다.
- Attachment zero 와 positive/passive modal core 는 deterministic construction 이다.
- Source-object group split 과 independent multi-resplat pairing 을 사용한다.
- Local 은 Gate C 통과 전 core claim 이 아니다.

명백한 수학/단위 오류를 제외하면 Gate evidence 전 새 physics backend, nonlinear latent Lagrangian, learned aerodynamics, contact solver 와 additional runtime stage 를 추가하지 않는다. 새 stage 가 필요하면 기존 stage 하나를 대체하고 reason/metric 을 manifest 에 남긴다.

15 최종 요약

새 Wind3DGS 는 training mesh 로 explicit scaffold 를 target 에 복원하는 방법이 아니다. Mesh simulation 은 response teacher 이고, static GS 는 target representation 이다. Patch 기반 encoder 는 density 가 다른 GS 를 fixed/capped latent token 으로 정리하고 내부 relation 과 global context 를 사용한다. 그 token 에서 area/mass measure, always-on passive Global response 와 complementary Local response dictionary 를 예측한다. Runtime 에는 wind load 가 package 를 excite 하고, 필요한 Local slot 만 fixed budget 에서 활성화된다.

성공 여부는 다음 네 질문으로 판정한다.

1. 같은 surface 의 independent GS density/seed 가 달라도 total work 와 response 가 일관되는가?
2. Target mesh, video, fine-tune 없이 held-out static GS 의 material 및 attachment 조건별 wind response 를 맞추는가?

3. Strong Global 보다 learned Local residual 이 실제 flutter/phase/PSD 를 복원하는가?
4. Conditional Local 이 same-p95 Pareto 와 renderer-ready visual quality 를 동시에 개선하는가?

네 질문에 순서대로 답하기 전에는 universal meshless dynamics, arbitrary object generalization, real-time 과 TOG-level contribution 을 주장하지 않는다.

References

- [1] Chen Geng, Guangzhao He, Yue Gao, Yunzhi Zhang, Shangzhe Wu, and Jiajun Wu. NeuROK: Generative 4d neural object kinematics. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 39239–39251, 2026. arXiv:2605.30347.
- [2] Andrew Jaegle, Sebastian Borgeaud, Jean-Baptiste Alayrac, Carl Doersch, Catalin Ionescu, David Ding, Skanda Koppula, Daniel Zoran, Andrew Brock, Evan Shelhamer, Olivier J. Hénaff, Matthew M. Botvinick, Andrew Zisserman, Oriol Vinyals, and João Carreira. Perceiver IO: A general architecture for structured inputs and outputs. *arXiv preprint arXiv:2107.14795*, 2021.
- [3] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4):139:1–139:14, 2023.
- [4] Yuanhang Lei, Boming Zhao, Zesong Yang, Xingxuan Li, Tao Cheng, Haocheng Peng, Ru Zhang, Yang Yang, Siyuan Huang, Yujun Shen, Ruizhen Hu, Hujun Bao, and Zhaopeng Cui. Diffwind: Physics-informed differentiable modeling of wind-driven object dynamics. In *International Conference on Learning Representations*, 2026. arXiv:2603.09668.
- [5] Yikun Ma, Yiqing Li, Jingwen Ye, Zhongkai Wu, Weidong Zhang, Lin Gao, and Zhi Jin. FastPhysGS: Accelerating physics-based dynamic 3DGS simulation via interior completion and adaptive optimization. *arXiv preprint arXiv:2602.01723*, 2026.
- [6] Vismay Modi, Nicholas Sharp, Or Perel, Shinjiro Sueda, and David I. W. Levin. Simplicits: Mesh-free, geometry-agnostic, elastic simulation. *ACM Transactions on Graphics*, 43(4), 2024.
- [7] Louen Pottier. LaGSplat: Inferring physics-governed interactive simulation from monocular video using latent lagrangian gaussian splatting. *arXiv preprint arXiv:2608.16324*, 2026.
- [8] Jiahong Wang, Yinwei Du, Stelian Coros, and Bernhard Thomaszewski. Neural modes: Self-supervised learning of nonlinear modal subspaces. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 23158–23167, 2024.
- [9] Donglai Xiang, Vismay Modi, Rishit Dagli, Ty Trusty, Gilles Daviet, Anka He Chen, Nicholas Sharp, and David I. W. Levin. Freeform: Reduced-order deformable simulation from particle-based skinning eigenmodes. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.

- [10] Tianyi Xie, Zeshun Zong, Yuxing Qiu, Xuan Li, Yutao Feng, Yin Yang, and Chenfanfu Jiang. Physgaussian: Physics-integrated 3d gaussians for generative dynamics. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [11] Hongru Yan, Xiang Zhang, Zeyuan Chen, Fangyin Wei, and Zhuowen Tu. Gaussian swaying: Surface-based framework for aerodynamic simulation with 3d gaussians. In *IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 4932–4942, 2026.